PRZEWIDYWANIE ZWROTÓW NA WYPRZEDAŻY

PROGRAM PREZENTACJI

- Cel projektu
- Porządkowanie danych i tworzenie zależności
- Porównanie modeli
- Wpływ na wyniki
- Ogólne podsumowanie projektu

CEL PROJEKTU

Na podstawie danych historycznych o wyprzedażach, sprzedaży, zatowarowaniu i cechach danych produktów mieliśmy zbudować model przewidujący ile sztuk danego produktu w danych kraju zostanie zwróconych przez klientów w każdym tygodniu wyprzedaży.

PODSTAWOWE INFORMACJE O ZMIENNYCH

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 295263 entries, 0 to 295262
Data columns (total 20 columns):
 #   Column                          Non-Null Count   Dtype
---  ------                          --------------   -----
 0   Season                          295263 non-null  object
 1   Channel                         295263 non-null  object
 2   STCL                            295263 non-null  object
 3   ClearanceWeek                   295263 non-null  int64
 4   RETU                            295263 non-null  float64
 5   Subclass                        295263 non-null  object
 6   SLSU                            258471 non-null  float64
 7   PriceDiffFromLastRegular        288720 non-null  float64
 8   StockCalculationDate            282918 non-null  float64
 9   Last2DaysSLSU                   295263 non-null  int64
 10  Last3DaysSLSU                   295263 non-null  int64
 11  Last4DaysSLSU                   295263 non-null  int64
 12  Last5DaysSLSU                   295263 non-null  int64
 13  BeforeClearanceSeasonSLSU       295263 non-null  float64
 14  Last2WeeksBeforeClearanceSLSU   295263 non-null  float64
 15  SbclSLSULY                      295263 non-null  int64
 16  FabricComposition               295218 non-null  object
 17  Line                            295263 non-null  object
 18  PredictionsSLSU                 88146 non-null   float64
 19  RETU_Regular                    295263 non-null  float64
dtypes: float64(8), int64(6), object(6)
memory usage: 45.1+ MB
```

- Ilość obserwacji: 295263
- Ilość kolumn: 20
- Występujące typy danych:
  - object
  - int64
  - float64

ROZKŁAD WPŁYWU SEZONU NA ZWROTY

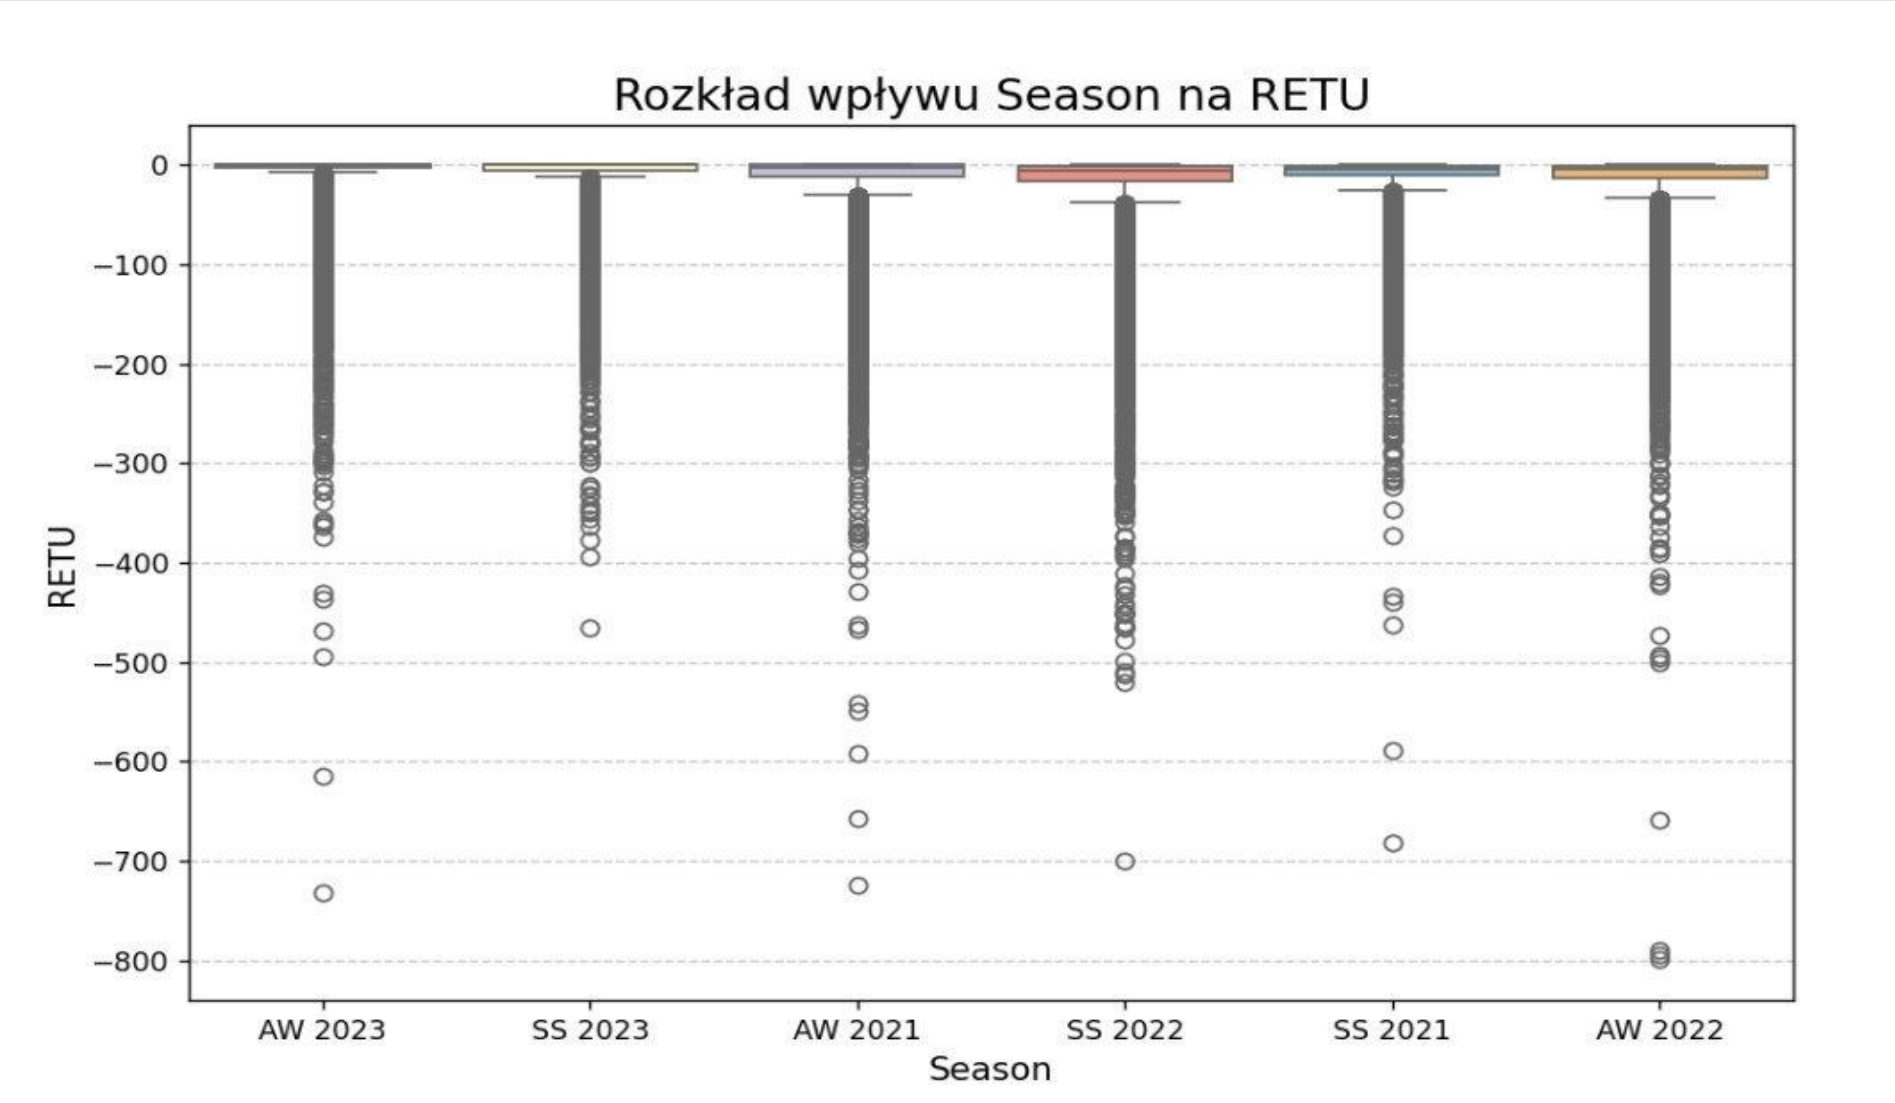

Rozkład wpływu okresu przedwyprzedażowego na sprzedaż sztukową

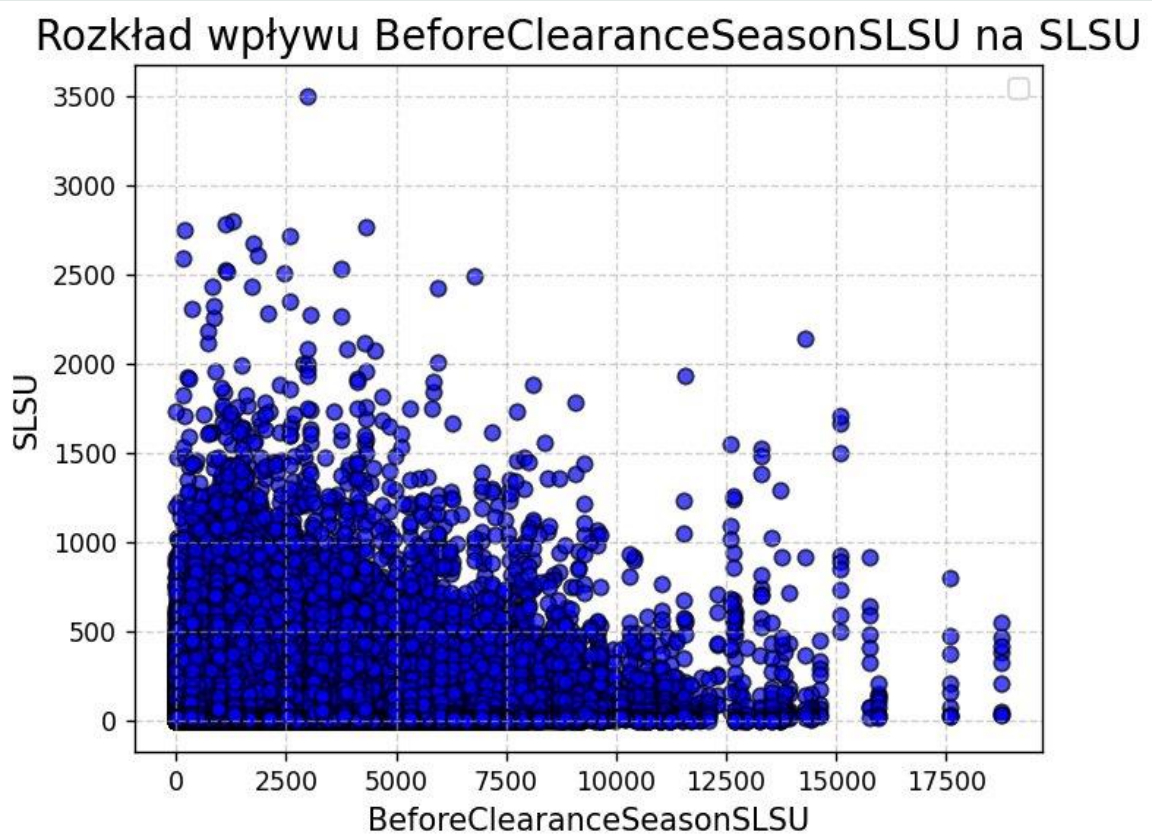

Rozkład wpływu wyprzedaży na zwroty

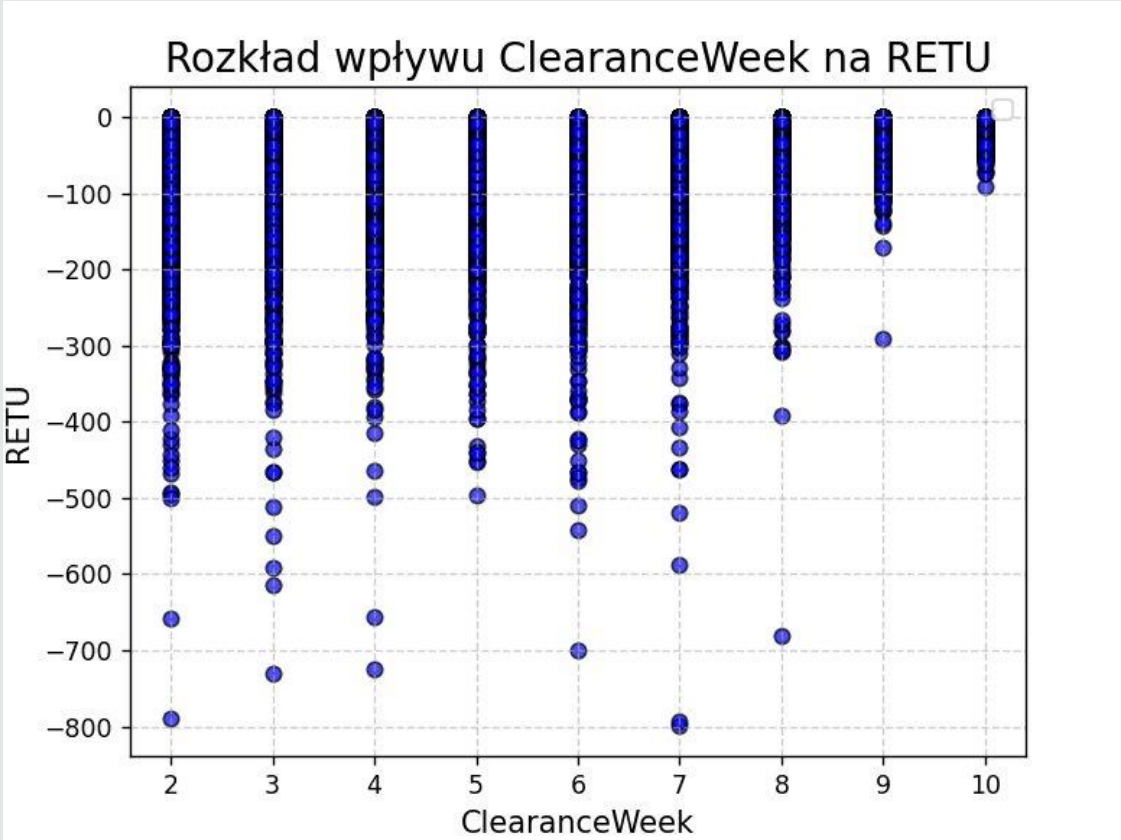

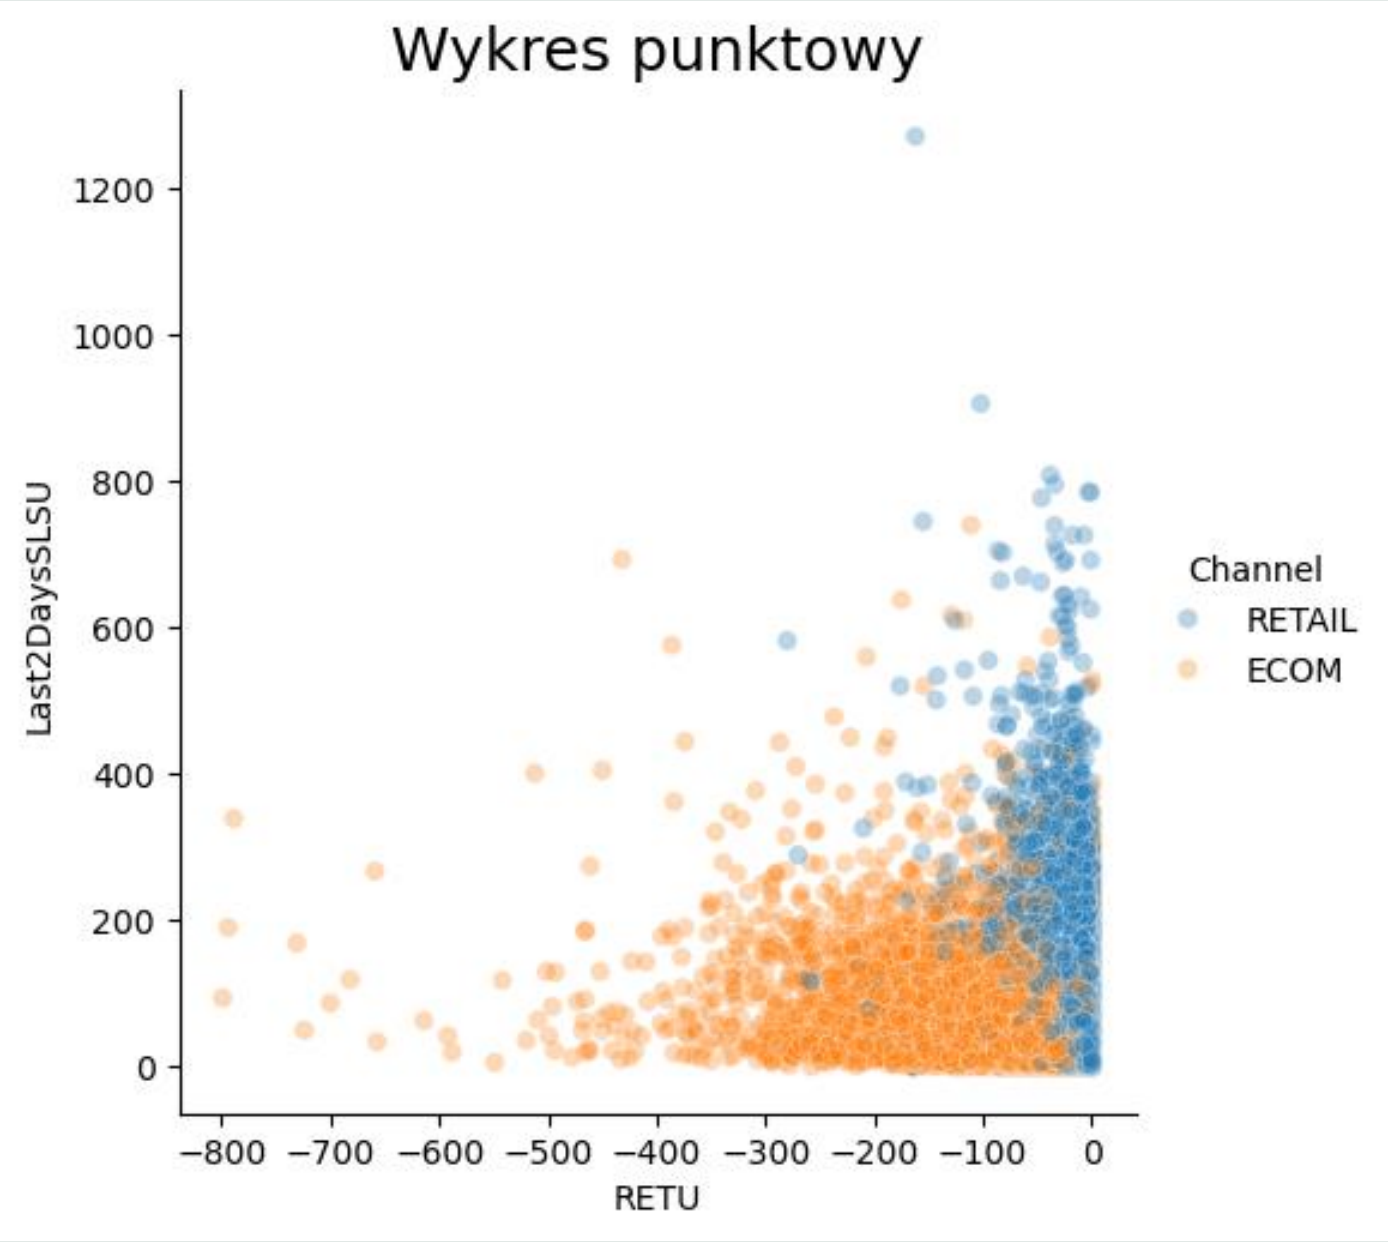
Wykres punktowy
Last2DaysSLSU
1200
1000
800
600
400
200
0
−800
−700
−600
−500
−400
−300
−200
−100
0
RETU
Channel
RETAIL
ECOM

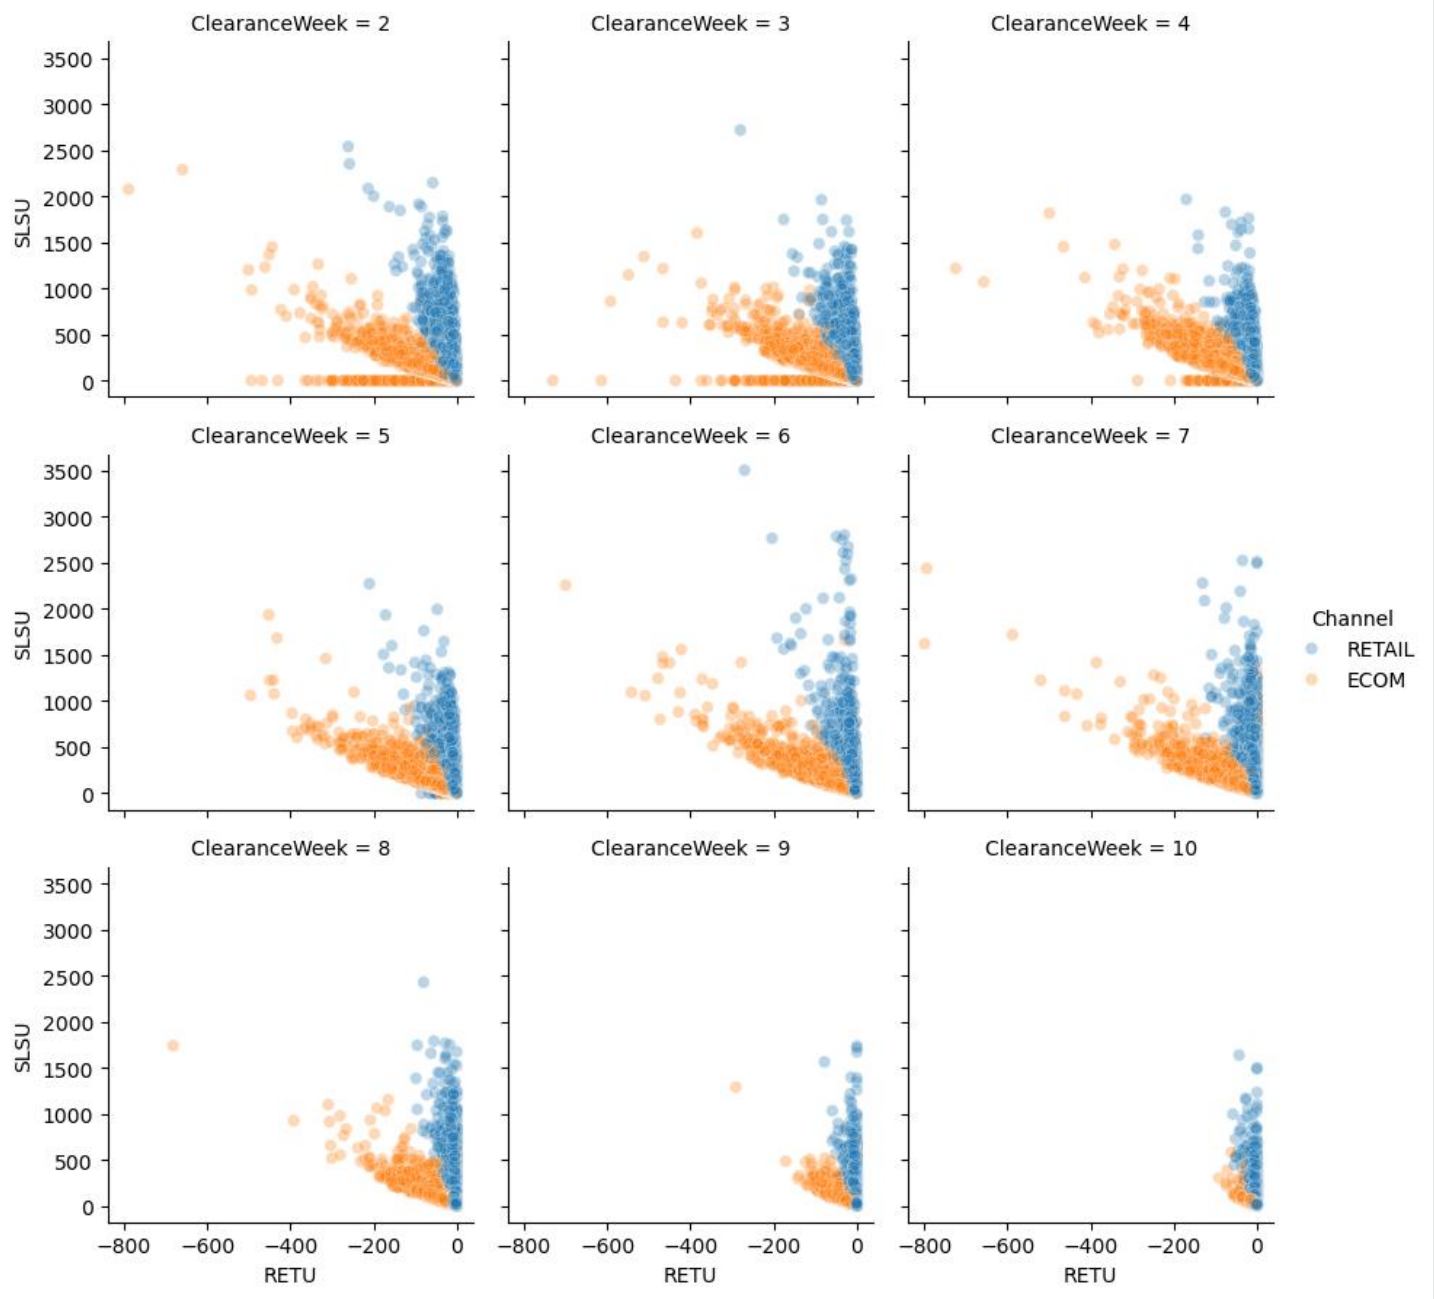
ClearanceWeek = 2
ClearanceWeek = 3
ClearanceWeek = 4
ClearanceWeek = 5
ClearanceWeek = 6
ClearanceWeek = 7
ClearanceWeek = 8
ClearanceWeek = 9
ClearanceWeek = 10
SLSU
RETU
Channel
RETAIL
ECOM

HISTOGRAM ZMIENNOŚCI RETU

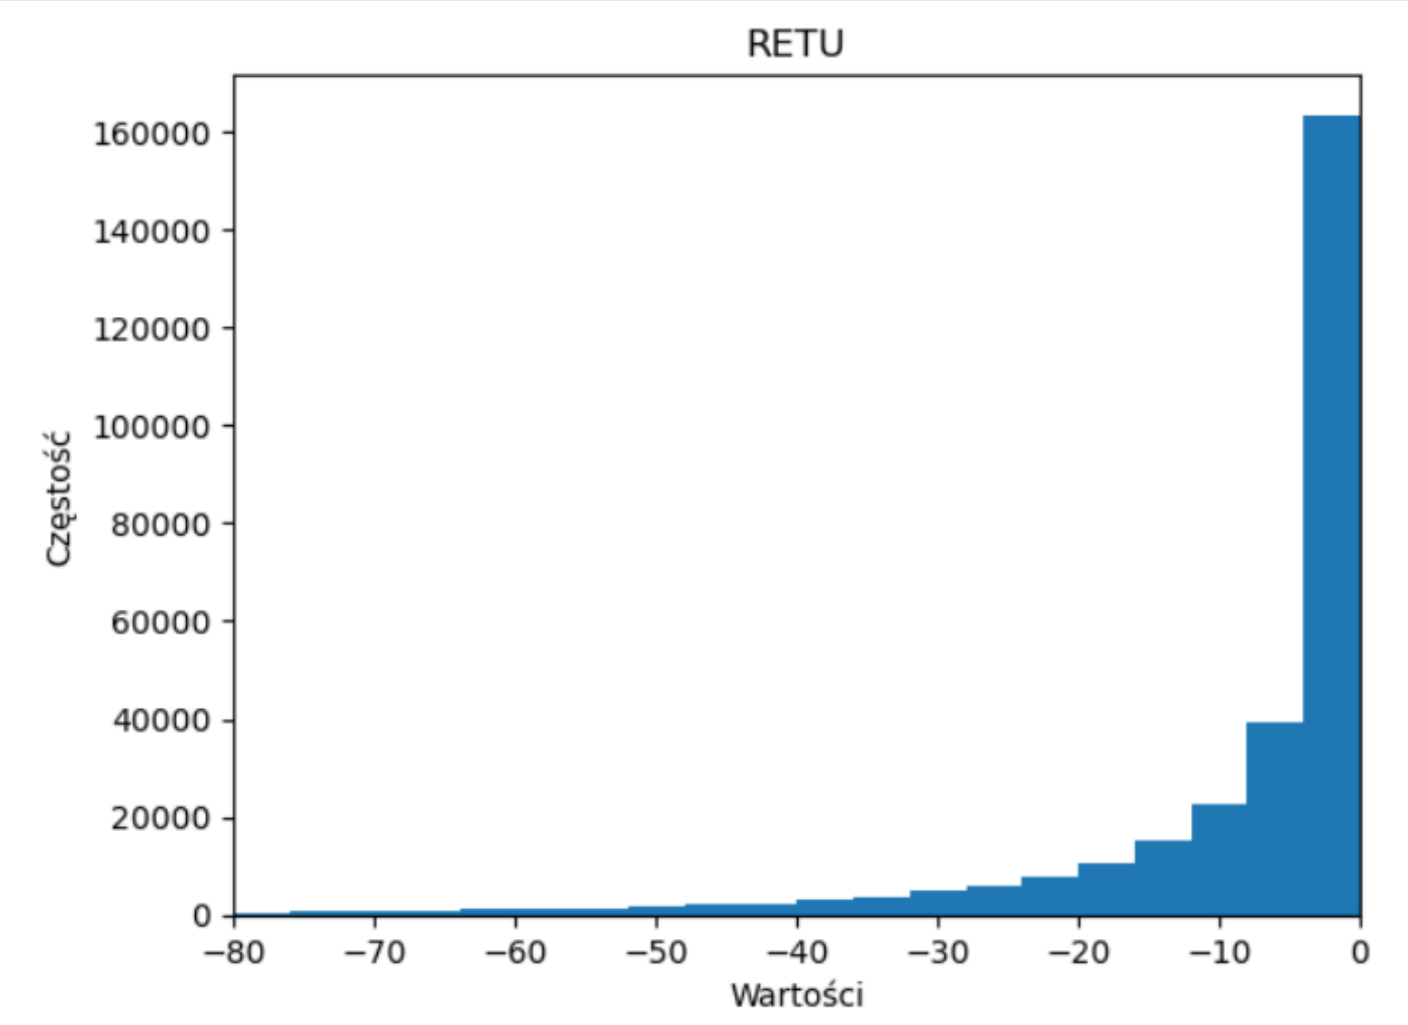

WYBRANIE DANYCH PO POPRAWIE KORELACJI

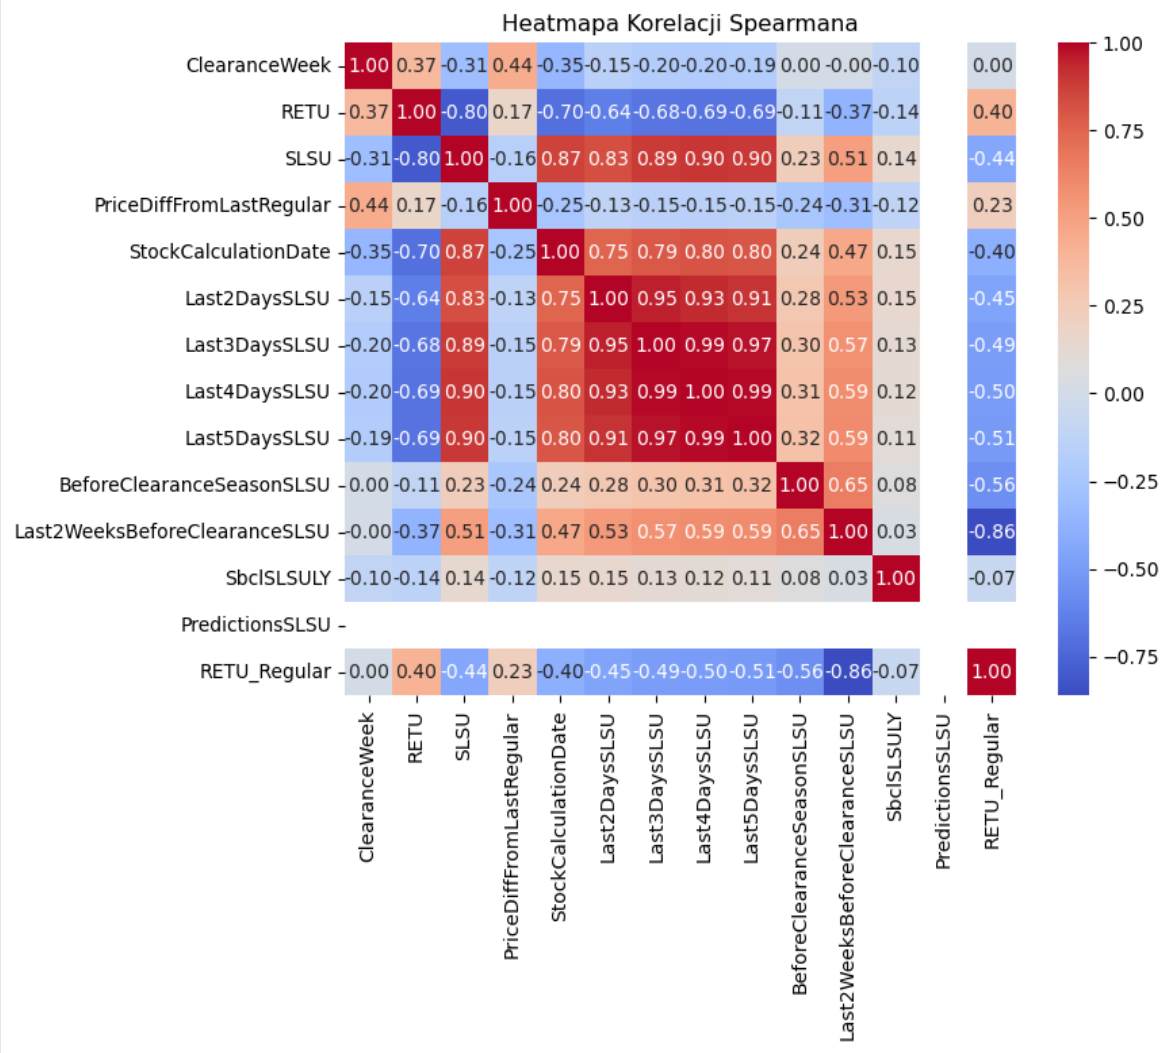

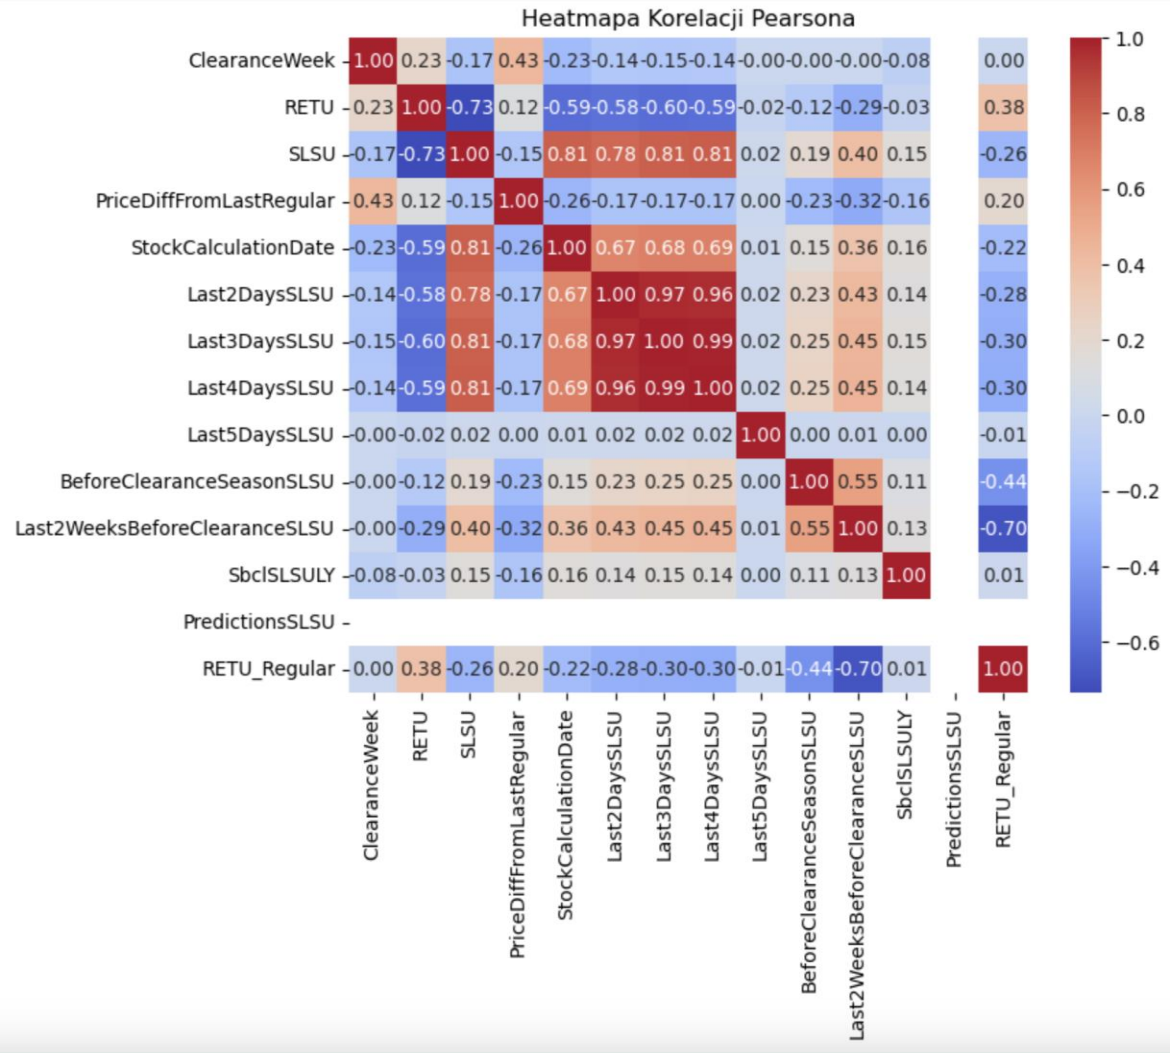

WYNIKI TESTOWANIA MODELI (REGRESJA LINIOWA)

['ClearanceWeek', 'PriceDiffFromLastRegular', 'StockCalculationDate', 'Last2DaysSLSU', 'Last3DaysSLSU', 'Last2WeeksBeforeClearanceSLSU', 'RETU_Regular', 'Subclass_encoded', 'Line_encoded']

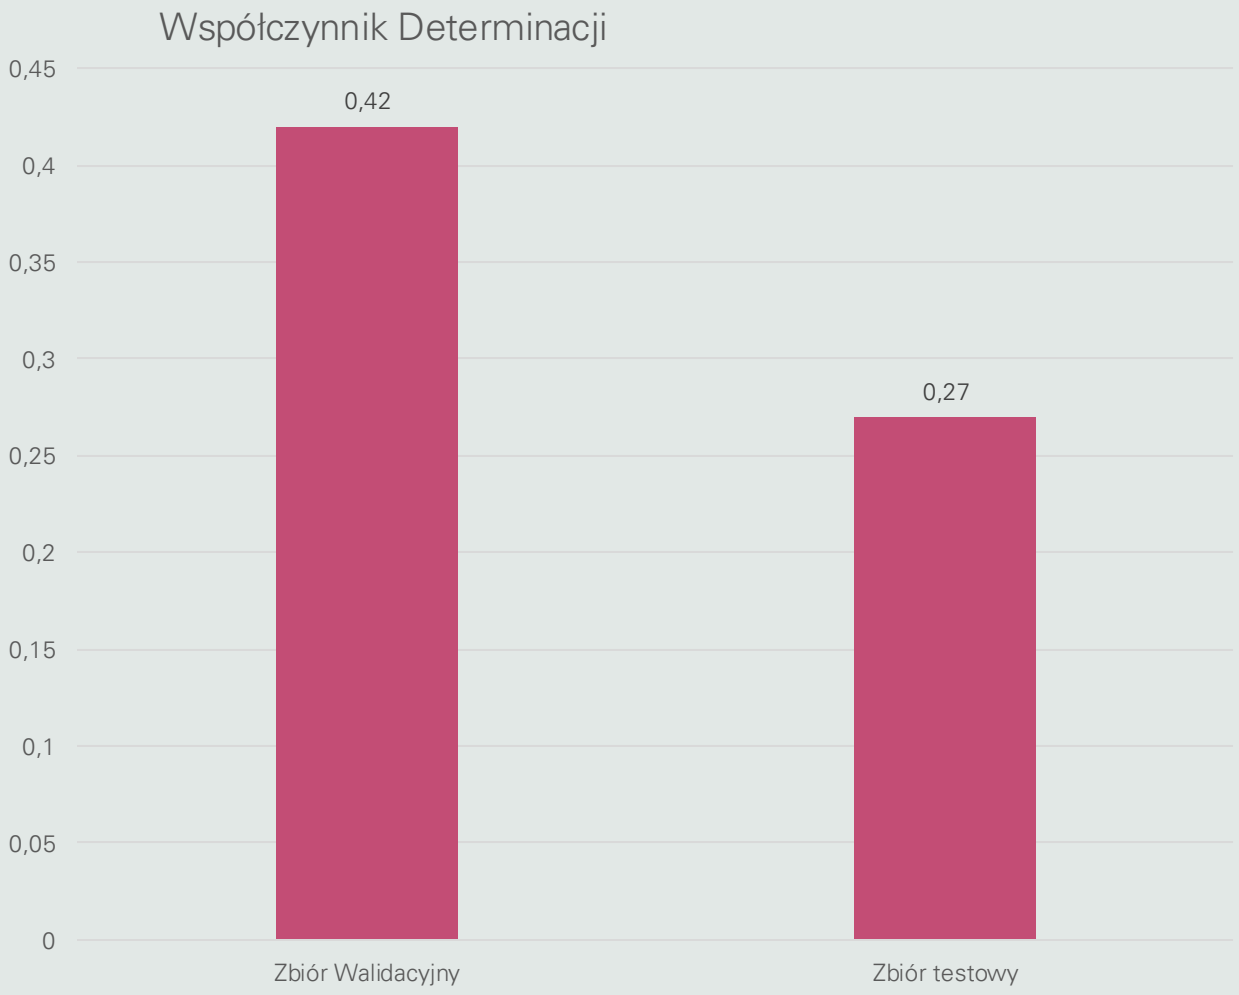

['ClearanceWeek', 'PriceDiffFromLastRegular', 'StockCalculationDate', 'Last2DaysSLSU', 'Last3DaysSLSU', 'Last2WeeksBeforeClearanceSLSU', 'RETU_Regular', 'Subclass_encoded', 'Line_encoded']

WYNIKI TESTOWANIA MODELI (REGRESJA LINIOWA)

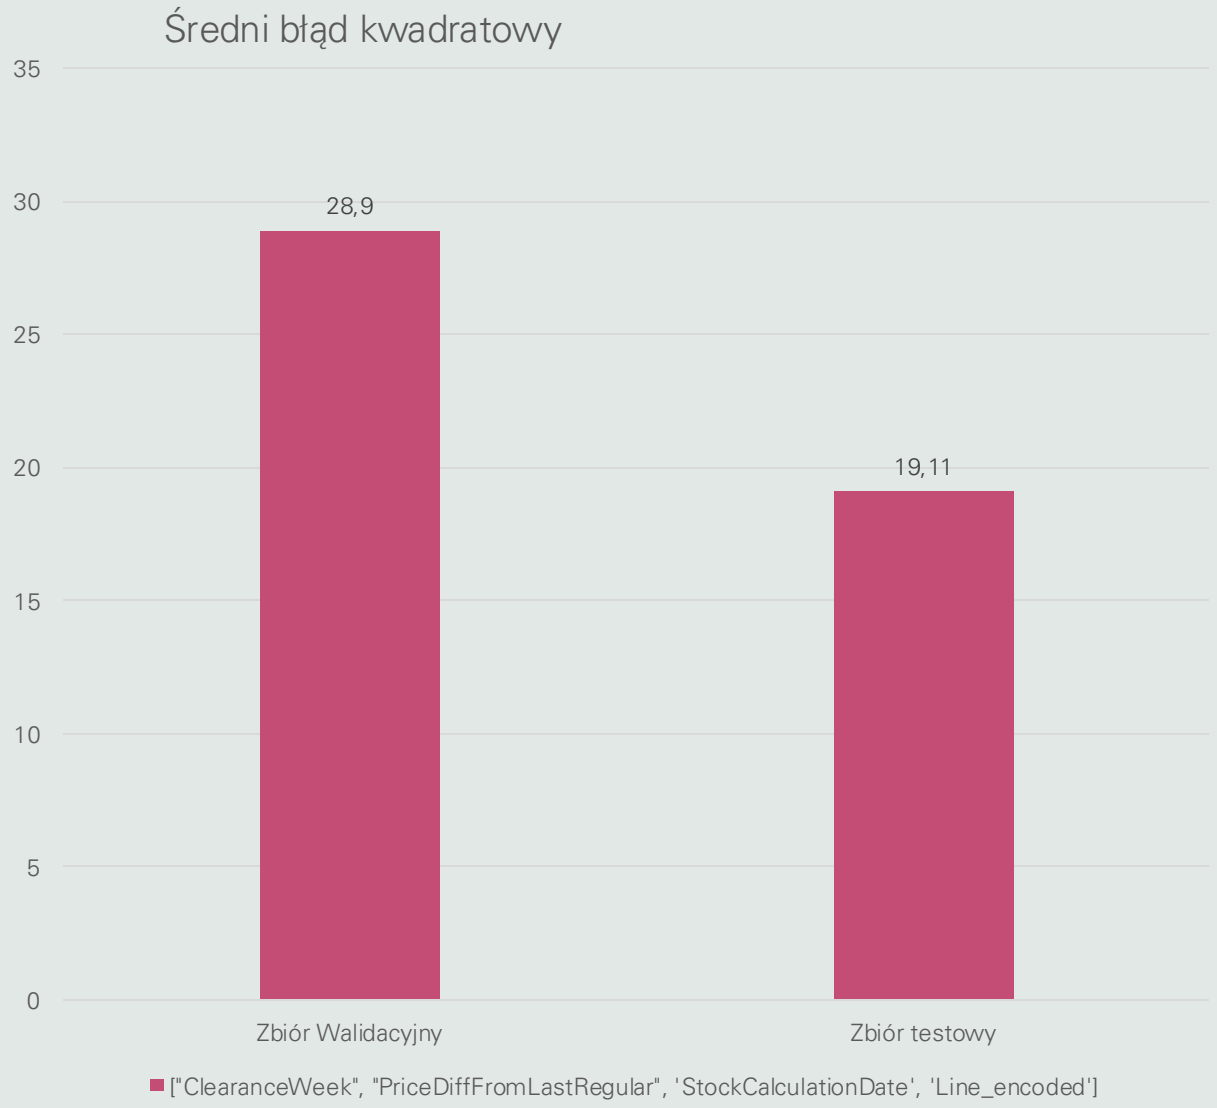

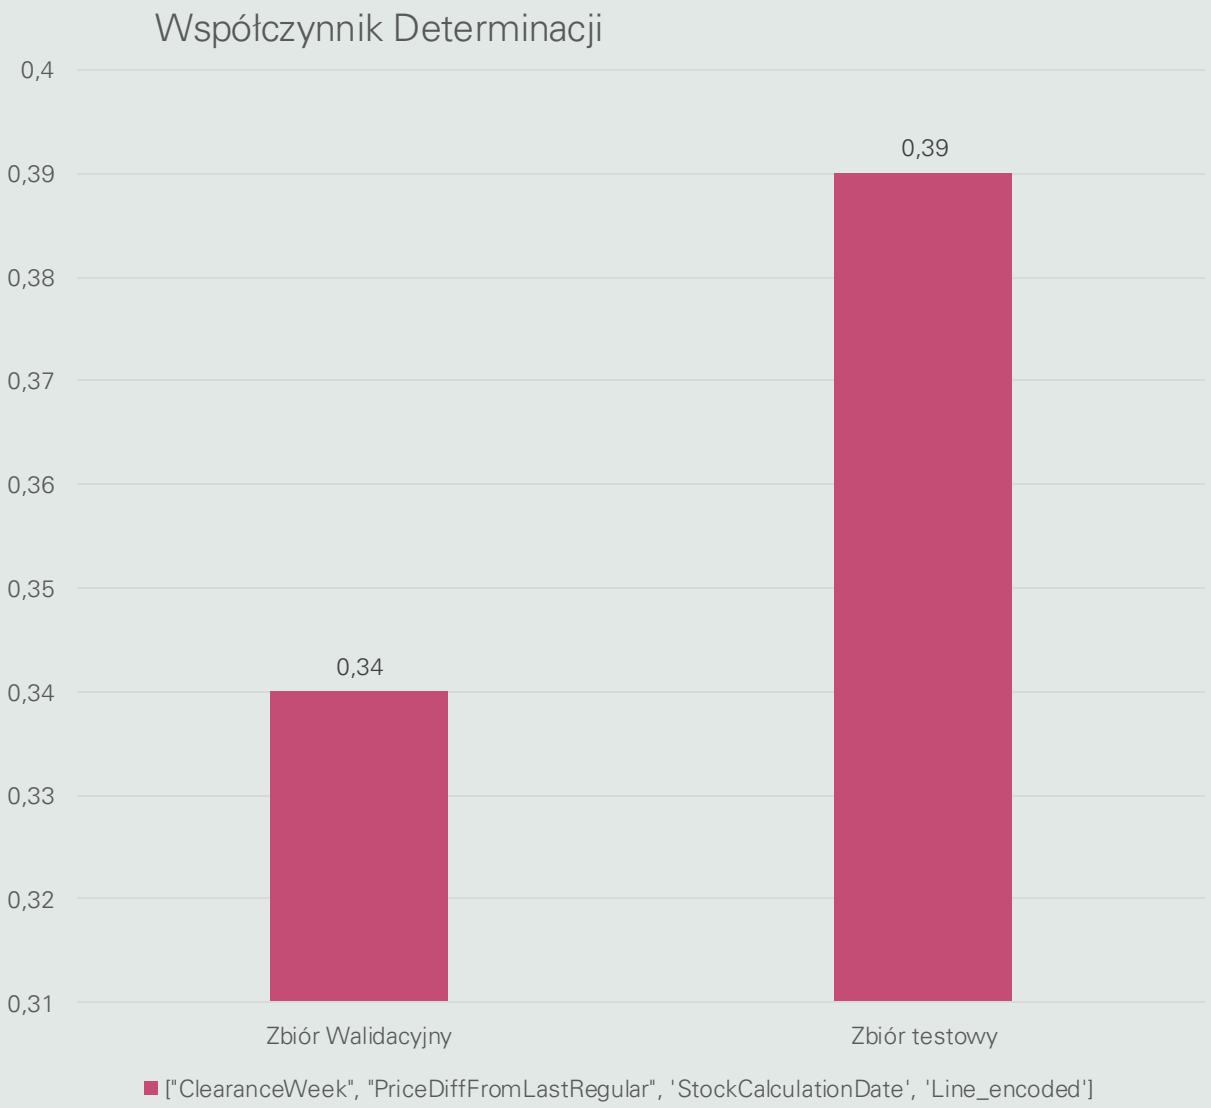

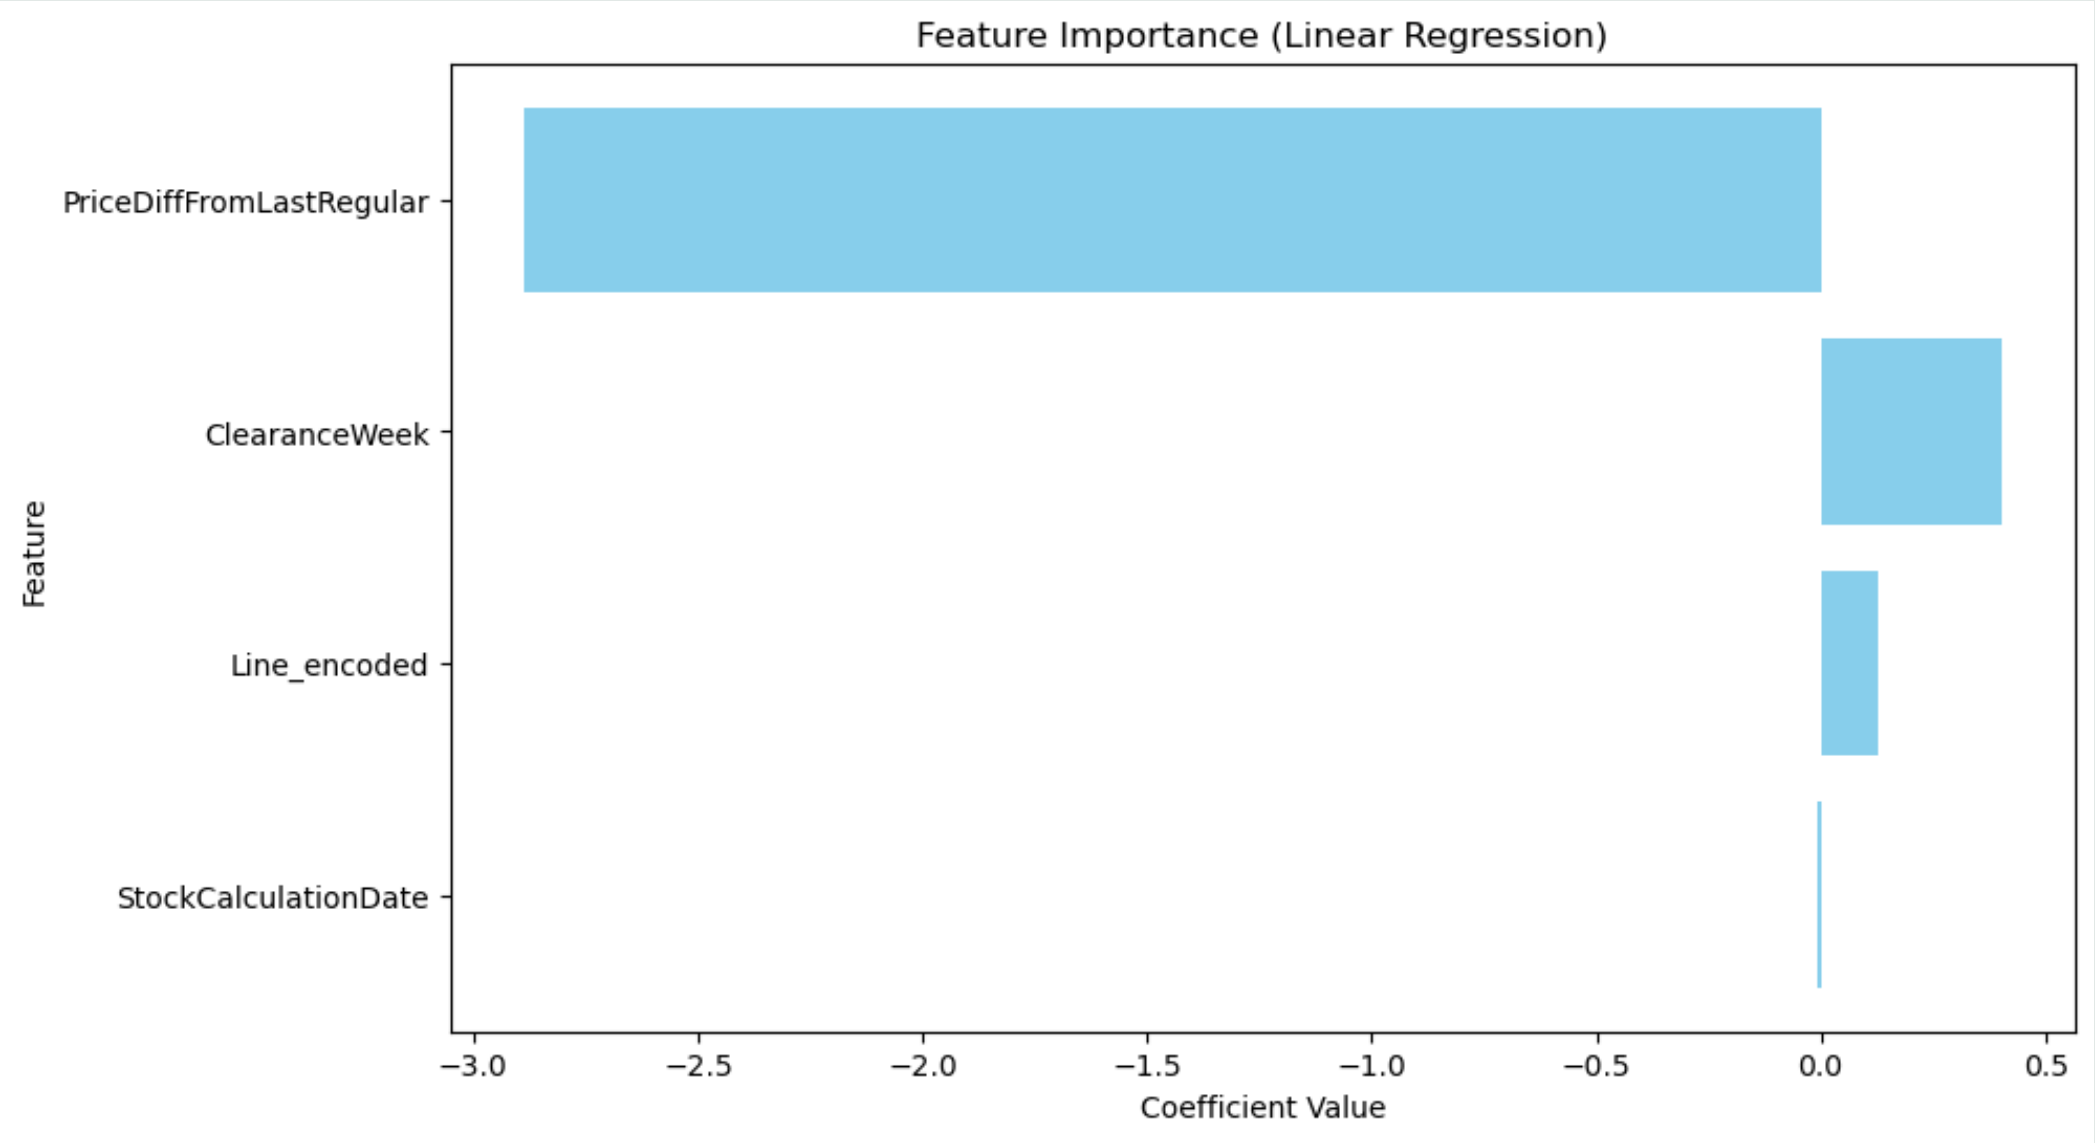
Feature Importance (Linear Regression)
PriceDiffFromLastRegular
ClearanceWeek
Line_encoded
StockCalculationDate
Feature
−3.0
−2.5
−2.0
−1.5
−1.0
−0.5
0.0
0.5
Coefficient Value

WYNIKI TESTOWANIA MODELI (LIGHTGBM)

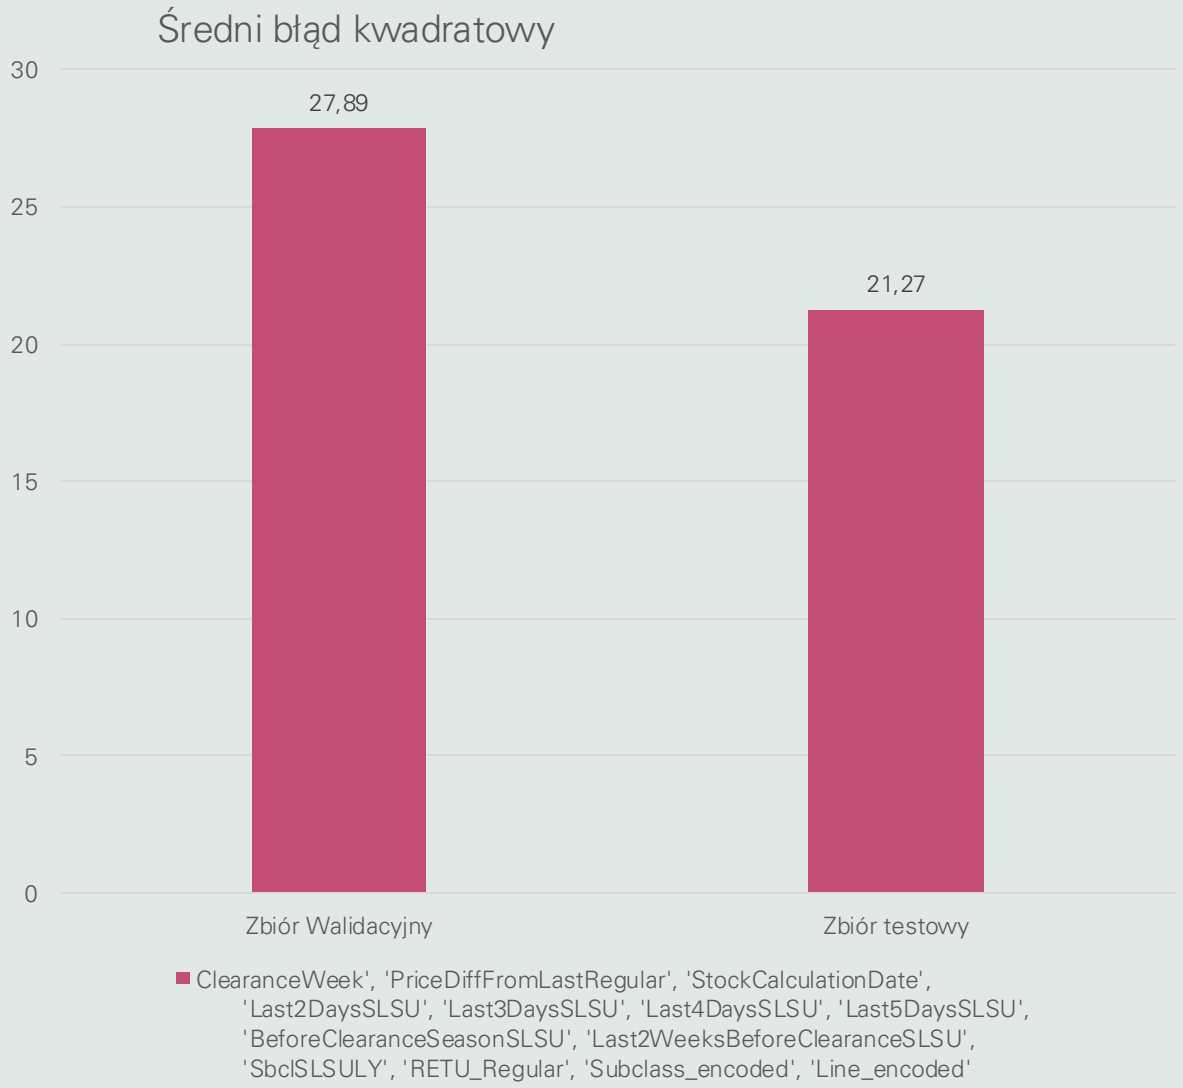

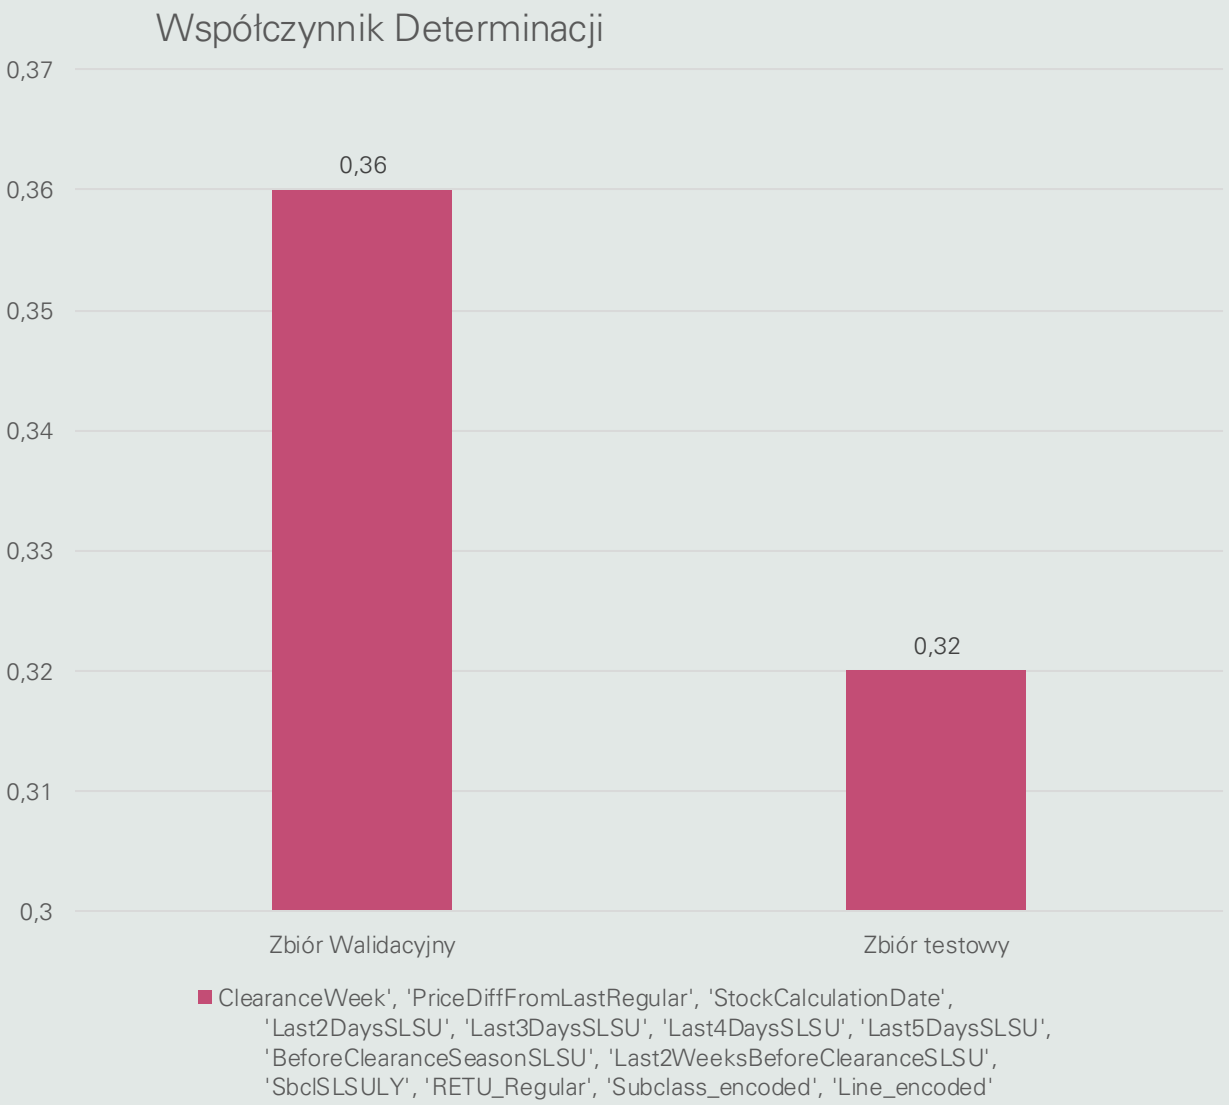

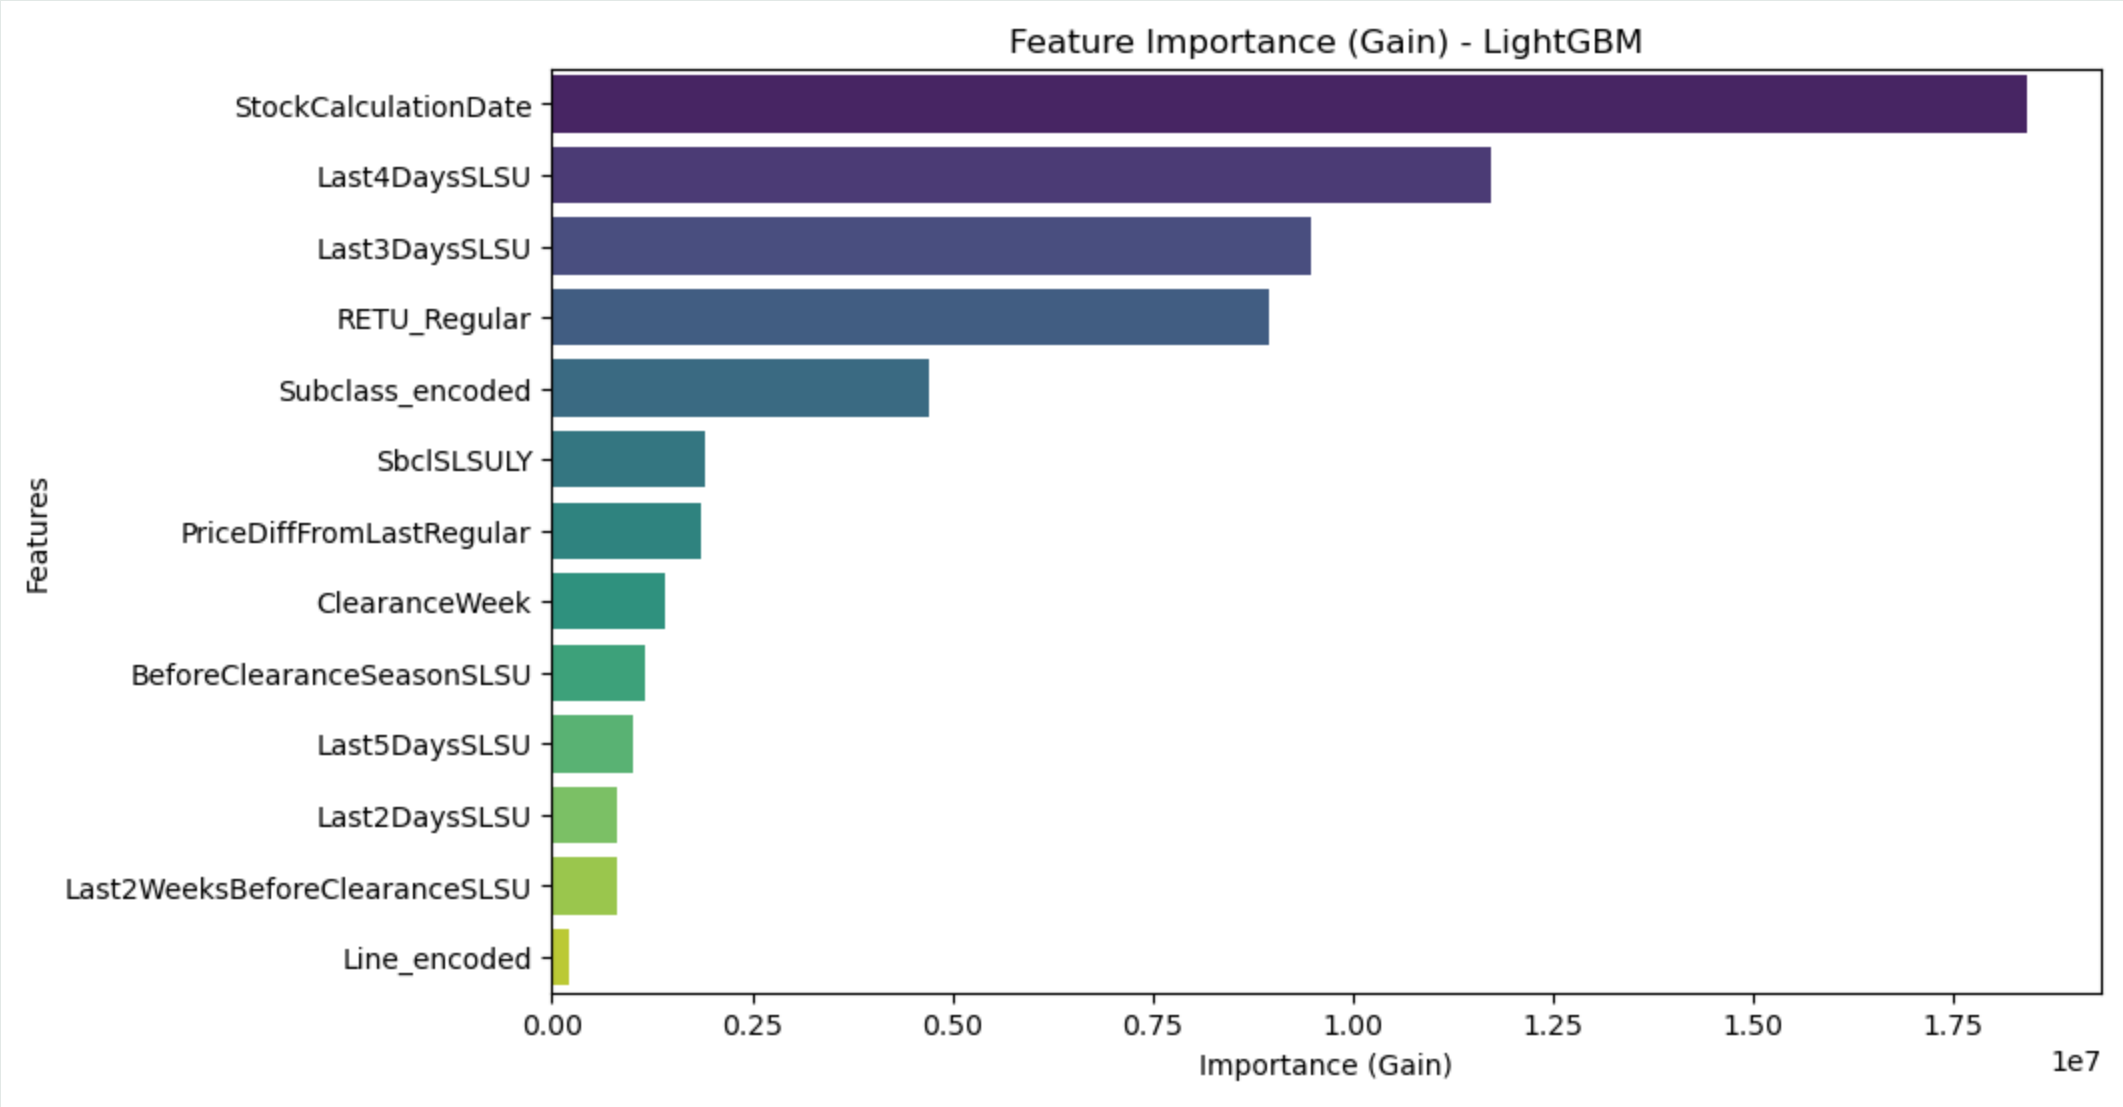
Feature Importance (Gain) - LightGBM
StockCalculationDate
Last4DaysSLSU
Last3DaysSLSU
RETU_Regular
Subclass_encoded
SbclSLSULY
PriceDiffFromLastRegular
ClearanceWeek
BeforeClearanceSeasonSLSU
Last5DaysSLSU
Last2DaysSLSU
Last2WeeksBeforeClearanceSLSU
Line_encoded
Features
0.00
0.25
0.50
0.75
1.00
1.25
1.50
1.75
1e7
Importance (Gain)

WYNIKI TESTOWANIA MODELI (LIGHTGBM)

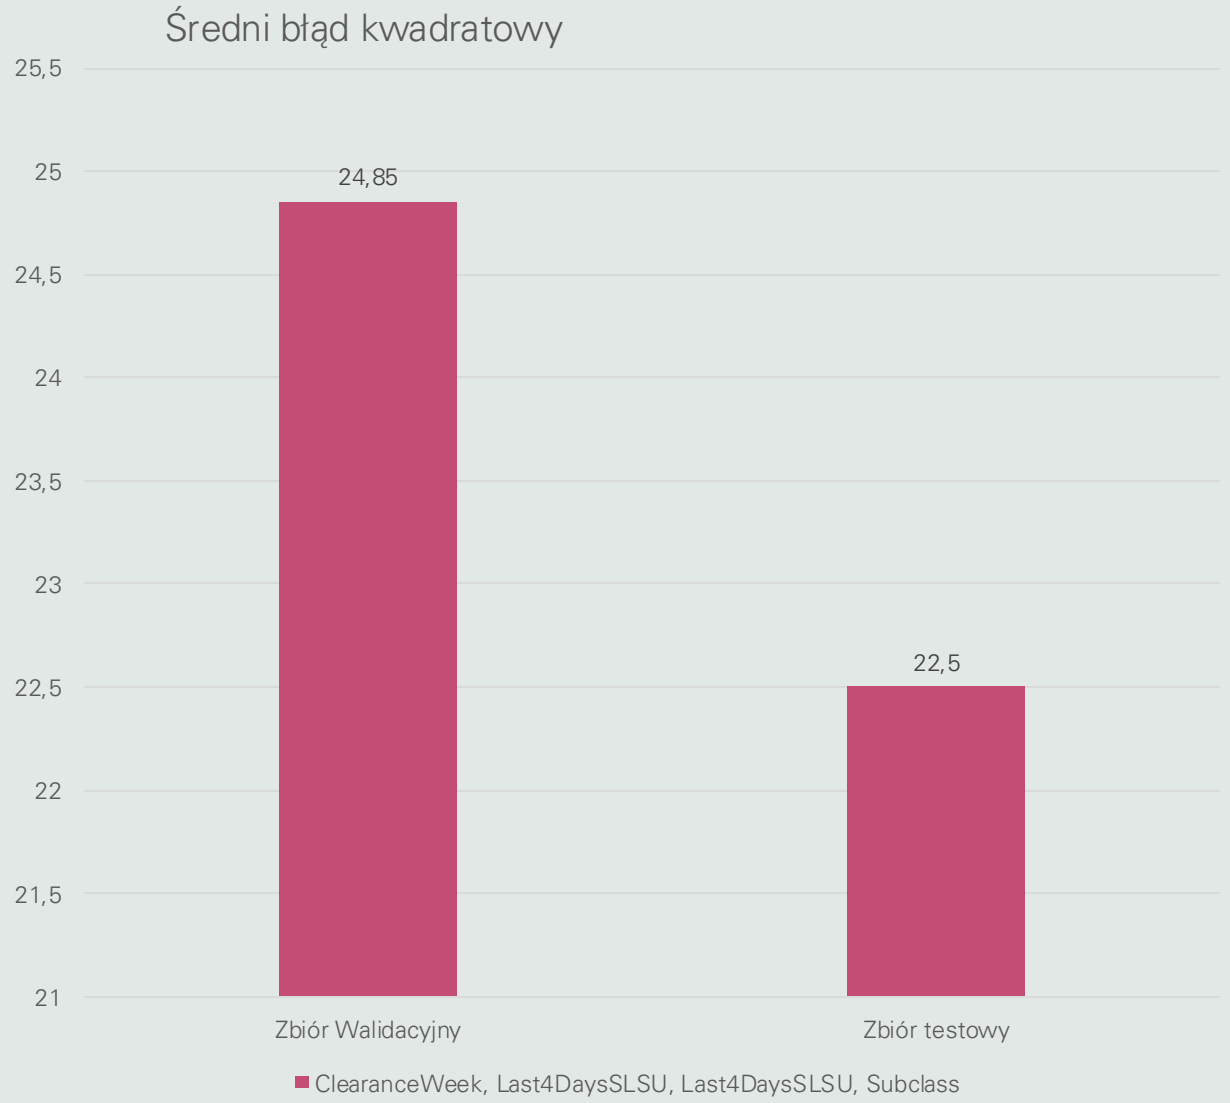

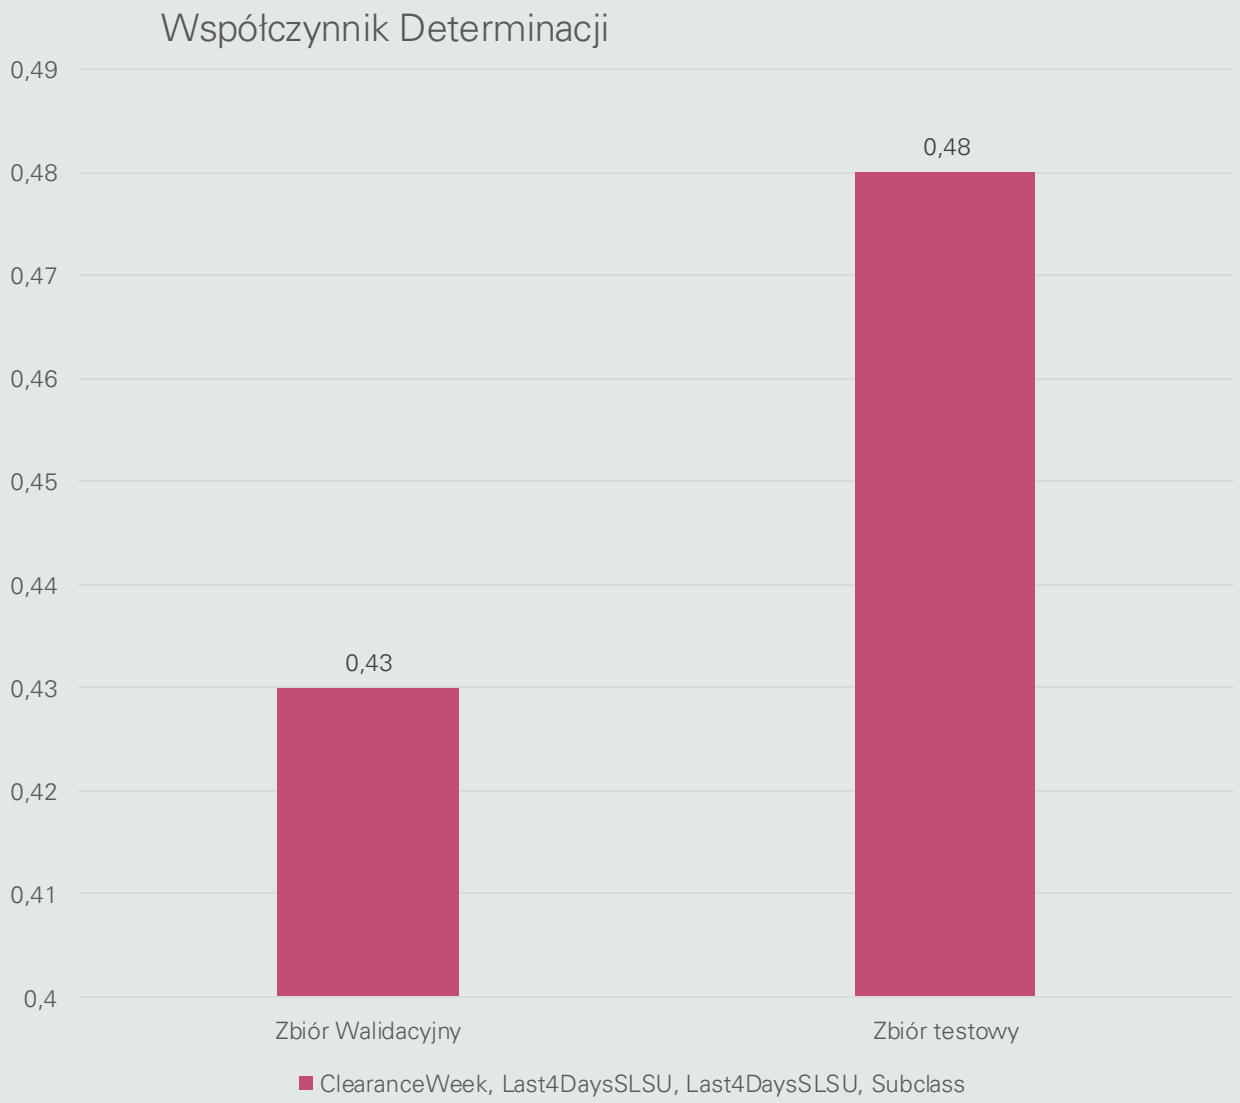

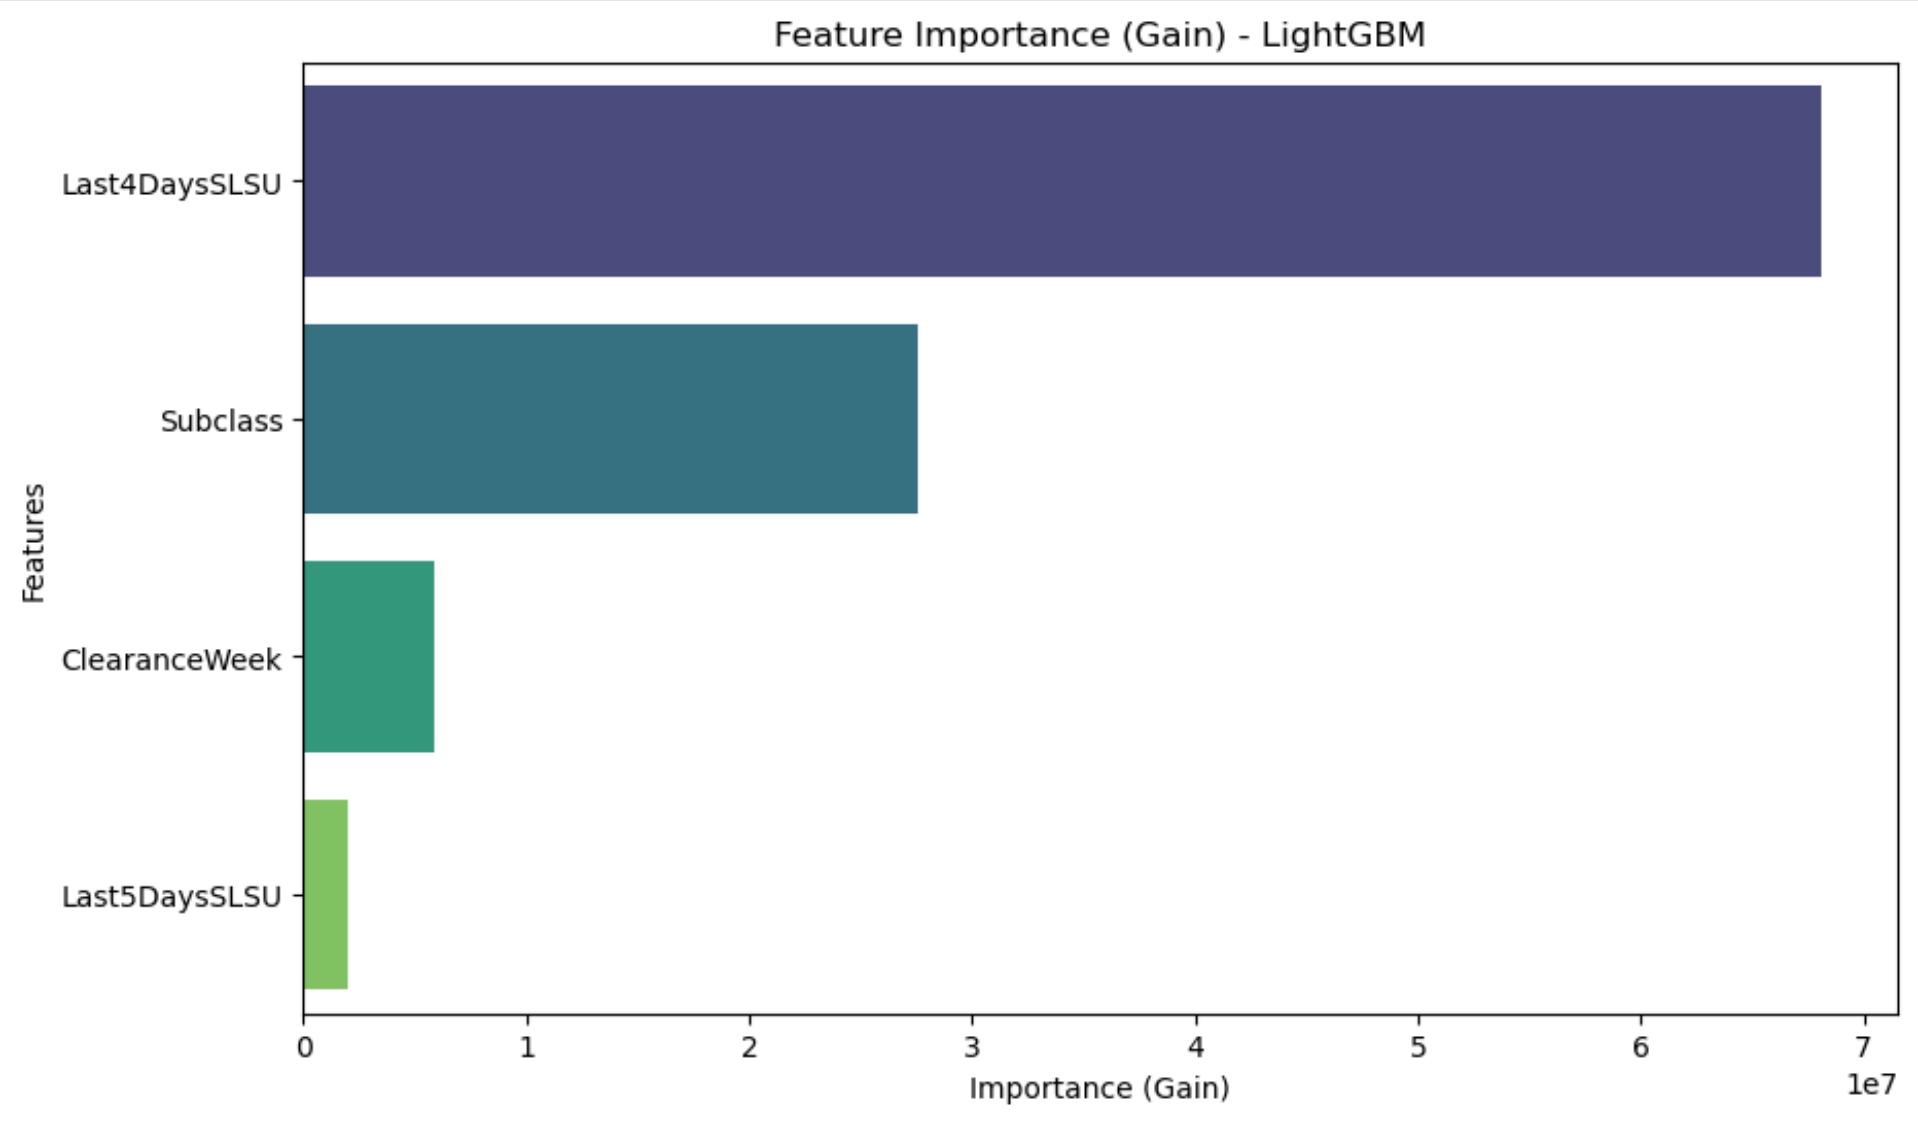
Feature Importance (Gain) - LightGBM
Last4DaysSLSU
Subclass
ClearanceWeek
Last5DaysSLSU
Features
0
1
2
3
4
5
6
7
1e7
Importance (Gain)

WYNIKI TESTOWANIA MODELI (XGBOOST)

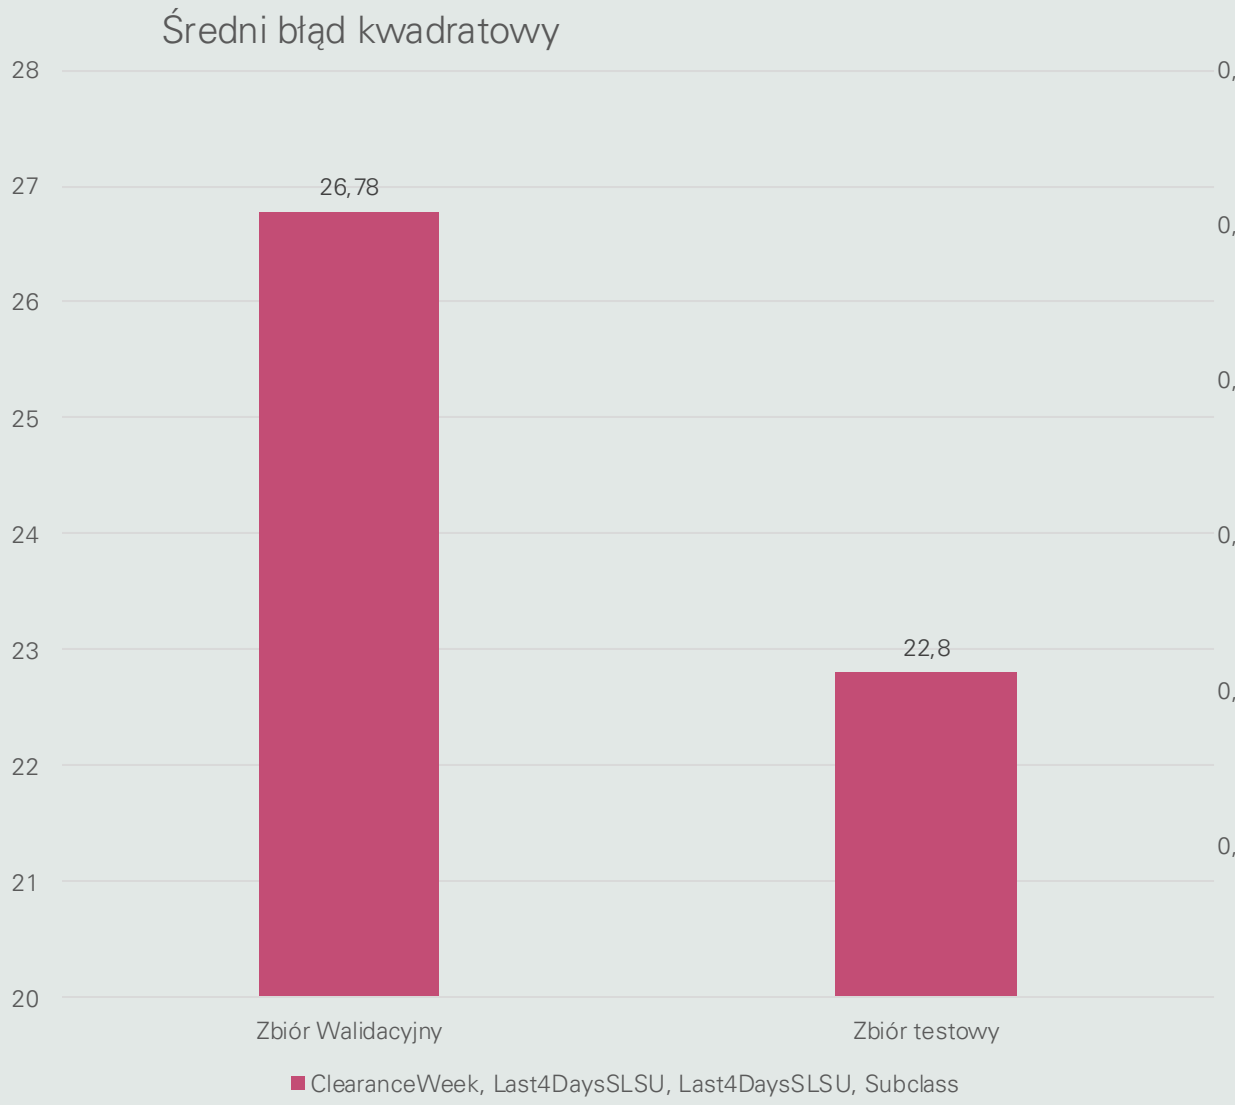

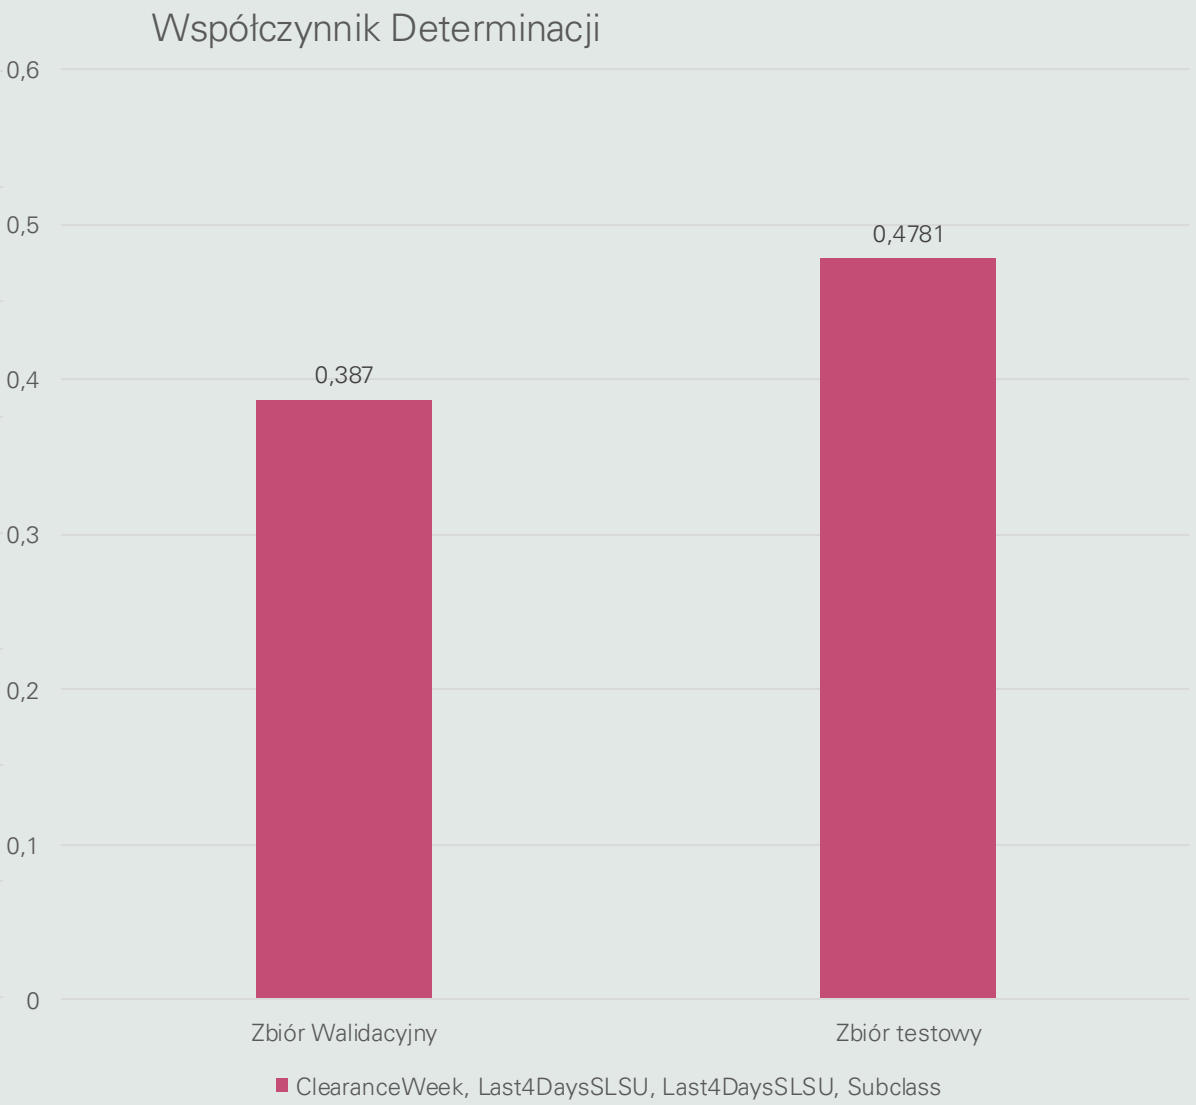

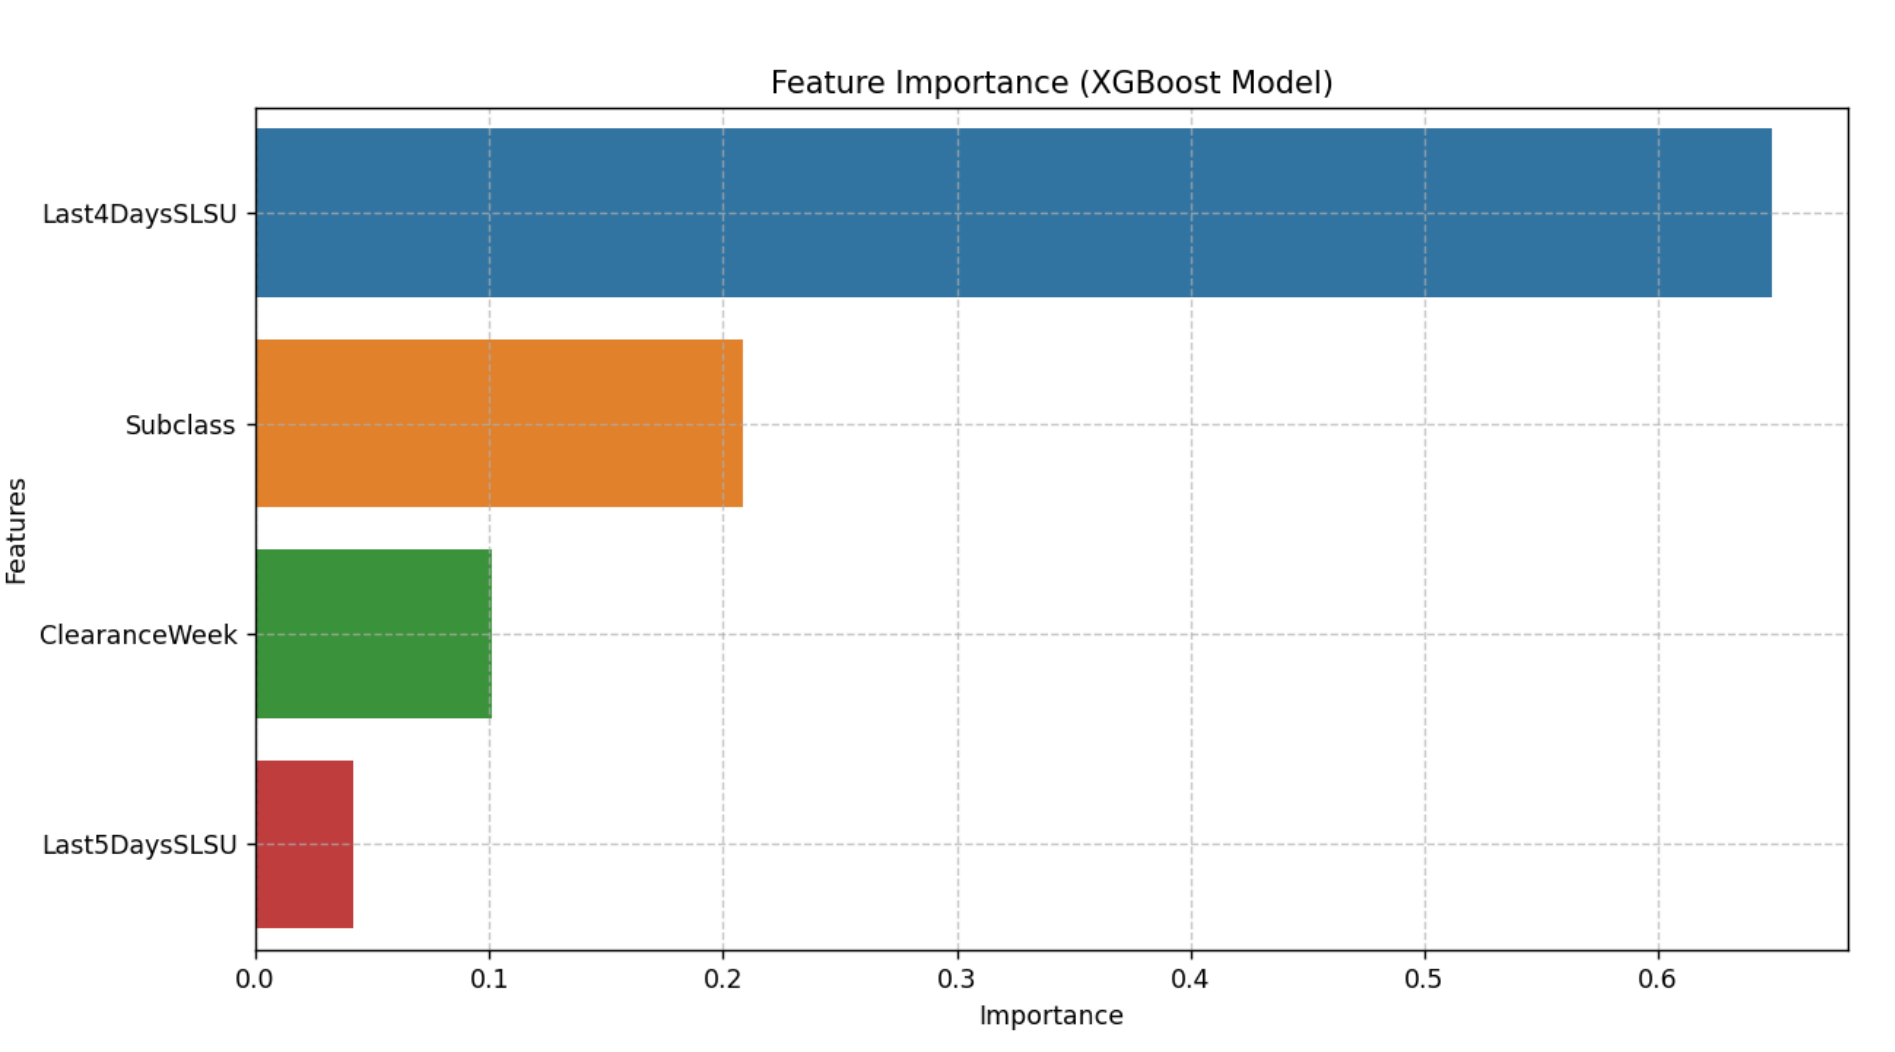
Feature Importance (XGBoost Model)
Last4DaysSLSU
Subclass
ClearanceWeek
Last5DaysSLSU
Features
0.0
0.1
0.2
0.3
0.4
0.5
0.6
Importance

PODSUMOWANIE MODELI

	Regresja Liniowa	Regresja Liniowa	LightGBM	LightGBM	XGBoost
MSE (valid)	25,25	28,90	**27,89**	24,85	26,79
R^2 (valid)	0,42	0,34	**0,36**	0,43	0,387
MSE (test)	22,92	19,11	**21,27**	22,50	22,80
R^2 (test)	0,27	0,39	**0,32**	0,48	0,4781

CO MOGŁO WPŁYNĄĆ NA NASZE PRZEWIDYWANIE?

- Oczekiwanie klientów na przecenienie konkretnych produktów
- Odsprzedawanie produktów po wyższej cenie na portalach aukcyjnych
- Niższa cena gwarantująca częstsze zdecydowanie się na zostawienie produktu
- Okres możliwości zwrotu (30 dni bez klubu, 365 przy posiadaniu karty klubowicza)

Vinted

allegro LOKALNIE

olx

PODSUMOWANIE

Najlepszy okazał się model LightGBM, gdzie wybraliśmy dość dużo zmiennych niezależnych, w tym także zmienne kategoryczne. Wartość R^2 są nieco niższe niż w przypadku dwóch ostatnich modeli, jednak tutaj przewyższa liczba zmiennych. Z wykresu wpływu widzimy, że w tym modelu zdecydowanie więcej zmiennych niezależnych wpływa na zmienną RETU.

DZIĘKUJEMY ZA UWAGĘ